Bagian A: Analisis Konseptual

1. **Efek Regularisasi pada Batch Normalization**

   - **Mekanisme Statistik:** Batch Normalization memiliki efek regularisasi ringan karena proses normalisasinya bergantung pada statistik (mean dan varians) dari mini-batch, bukan keseluruhan dataset. Setiap kali data latih (sebuah input image) melewati Batch Normalization dalam mini-batch yang berbeda, mean dan varians dari mini-batch tersebut akan sedikit berbeda. Hal ini menambahkan *noise* atau variasi pada representasi data tersebut selama pelatihan. Penambahan *noise* statistik pada setiap mini-batch ini memaksa model untuk tidak terlalu bergantung pada satu set fitur spesifik atau "menghafal" data latih (overfitting), sehingga meningkatkan kemampuan generalisasi model. Hal ini serupa dengan efek Dropout yang menambahkan *noise* dengan mematikan neuron secara acak.

   - **Kondisi Mengurangi/Menghilangkan Dropout:** Asumsi bahwa Batch Normalization "menghilangkan Dropout" mungkin tidak berlaku dan bisa memicu instabilitas pada skenario ukuran mini-batch yang sangat kecil (misal, batch size 2 atau 4). Pada mini-batch kecil, estimasi mean dan varians menjadi tidak stabil dan tidak representatif dari distribusi populasi keseluruhan. *Noise* yang ditambahkan menjadi terlalu besar dan tidak beraturan, mengganggu proses pembelajaran. Selain itu, pada kasus *Transfer Learning* ketika kita melakukan *fine-tuning* pada dataset yang sangat berbeda dari dataset awal, mengandalkan statistik Batch Normalization yang dihitung pada *batch* kecil (karena keterbatasan memori saat melatih model besar) dapat menyebabkan performa memburuk.

2. **Degradasi Jaringan Dalam dan Formulasi Residual**

   - **Degradasi Performa:** Secara teori, menambahkan layer pada *plain CNN* seharusnya minimal mempertahankan performa (melalui *identity mapping*), namun praktiknya justru menurunkan akurasi (*degradation problem*). Hal ini bukan disebabkan oleh overfitting, melainkan karena semakin dalam jaringan, semakin sulit bagi proses optimasi untuk menemukan *identity mapping* tersebut. Gradien cenderung menghilang (*vanishing*) atau meledak (*exploding*) saat di-propagasi mundur melewati banyak lapisan *non-linear* berurutan. Akibatnya, bobot di lapisan awal tidak diperbarui secara efektif, dan informasi dari input awal perlahan "hilang" (information loss) sebelum mencapai lapisan akhir, membuat model kesulitan mempelajari pemetaan yang kompleks.

   - **Peran Skip Connection dan Mitigasi Vanishing Gradient:** *Skip connection* (atau koneksi residual) mengatasi masalah ini dengan menambahkan kembali input (x) ke *output* dari sebuah blok *layer*, formulasinya menjadi $y = F(x) + x$. Saat *backpropagation*, *skip connection* menyediakan "jalan pintas" (shortcut) langsung untuk aliran gradien. Gradien tidak hanya mengalir melalui lapisan-lapisan fungsi $F(x)$, tetapi juga "melompat" melewati koneksi identitas x secara langsung ke lapisan sebelumnya. Jalur alternatif ini mencegah gradien menyusut

menjadi nol (*vanishing gradient*), sehingga layer-layer yang lebih dalam tetap bisa menerima sinyal *error* yang kuat dan proses *training* menjadi lebih stabil, memungkinkan pembangunan jaringan yang jauh lebih dalam seperti ResNet.

3. Feature Extraction vs. Fine-Tuning

Perbandingan *Feature Extraction* dan *Fine-Tuning*:

Dimensi	Feature Extraction (Bekukan Backbone)	Fine-Tuning (Buka Sebagian/Seluruh Lapisan)
Jumlah Parameter yang Diperbarui	Sangat sedikit (hanya classifier head).	Banyak (classifier head + sebagian/seluruh layer backbone).
Kebutuhan Data Latih	Minimal (baik untuk *small dataset*).	Membutuhkan lebih banyak data (terutama jika membuka banyak layer) untuk menghindari overfitting.
Beban Komputasi & Memori per Epoch	Rendah (backpropagation hanya pada layer akhir).	Tinggi (backpropagation melalui layer-layer yang di-unfreeze).
Risiko Destructive Gradient Updates	Rendah (karena bobot pretrained dikunci).	Tinggi (jika *learning rate* terlalu besar di awal, dapat merusak bobot pretrained).

Kriteria Pemilihan Praktis:

- **Feature Extraction:** Paling tepat dipilih ketika dataset target **sangat kecil** dan mirip dengan dataset sumber (seperti *ImageNet*). Selain itu, ini adalah pilihan utama ketika **anggaran komputasi sangat terbatas**.
- **Fine-Tuning:** Lebih disarankan ketika dataset target **cukup besar**, atau memiliki karakteristik visual yang berbeda secara signifikan dari dataset sumber. *Fine-tuning* berpotensi memberikan performa maksimal karena fitur disesuaikan spesifik untuk domain target, asalkan dilakukan secara bertahap dan dengan *learning rate* rendah.

4. Kaidah Penerapan Data Augmentation

- **Pertimbangan Metodologis:** *Data augmentation* hanya diaktifkan pada data latih (train set) untuk **menyimulasikan variasi dan memperbanyak sampel data**, sehingga model belajar untuk mengenali fitur yang kebal (*invariant*) terhadap rotasi, pergeseran, atau perubahan warna. Sebaliknya, augmentasi **harus dinonaktifkan** pada set validasi dan uji. Data validasi dan uji berfungsi sebagai proksi evaluasi pada data nyata yang tidak terlihat (*unseen real-world data*). Jika kita menambahkan distorsi augmentasi pada set pengujian, kita akan mengevaluasi model pada data yang artifisial, sehingga tidak mencerminkan performa model sebenarnya di dunia nyata. Evaluasi harus dilakukan pada data yang tidak diubah agar terukur dengan akurat.
- **Contoh Teknik yang Tidak Layak:** Untuk klasifikasi ras hewan peliharaan (*pet breeds*), teknik transformasi **Rotasi Vertikal (*Vertical Flip* / membalik gambar atas ke bawah)** sangat tidak disarankan. Anjing atau kucing di dunia nyata jarang (atau hampir tidak pernah) dilihat dalam posisi terbalik sepenuhnya (kaki di atas, kepala di bawah). Memaksa model mempelajari representasi hewan terbalik justru

merusak invariansi semantik dari label (mengubah makna visual dari objek anjing/kucing), membingungkan model, dan berpotensi menurunkan akurasi pada gambar normal.

5. **Mitigasi Catastrophic Forgetting**

- **Terjadinya Fenomena:** *Catastrophic forgetting* (hilangnya representasi bawaan) terjadi ketika model pretrained (seperti ResNet yang dilatih di *ImageNet*) tiba-tiba dilatih (*fine-tuned*) pada dataset baru dengan **learning rate yang besar** secara langsung pada seluruh lapisan. Sinyal *error* besar yang dihasilkan di awal pelatihan akan langsung merambat ke lapisan awal dan tengah, merusak ("menghapus") fitur-fitur fundamental (seperti deteksi tepi, tekstur, atau bentuk dasar) yang telah dipelajari sebelumnya dan sudah sangat baik.

- **Strategi Mitigasi:**

    1. **Differential Learning Rate:** Menggunakan *learning rate* yang berbeda untuk setiap lapisan. Layer yang lebih dalam (dekat output) diberikan *learning rate* lebih besar untuk beradaptasi cepat dengan dataset baru, sedangkan layer yang lebih awal (dekat input) diberi *learning rate* sangat kecil (atau bahkan nol). Secara teoritis, ini melindungi fitur general yang sudah dipelajari (di layer awal) sambil tetap memungkinkan penyesuaian khusus (di layer akhir).

    2. **Gradual Unfreezing:** Mulai dengan *Feature Extraction* (semua layer dibekukan kecuali *classifier head*). Setelah *classifier* mulai konvergen, secara bertahap buka (*unfreeze*) layer di bawahnya (satu blok layer dalam satu waktu) sambil terus melakukan pelatihan dengan *learning rate* kecil. Secara teoritis, strategi ini memberikan kesempatan bagi *classifier* baru untuk beradaptasi terlebih dahulu, sehingga ketika *backbone* mulai dibuka, gradien yang merambat mundur tidak terlalu agresif dan tidak merusak fitur lama.

Bagian B: Eksperimen Praktik

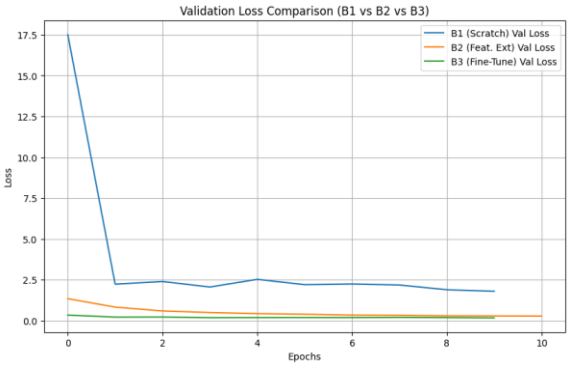
Dilampirkan dalam file .ipynb

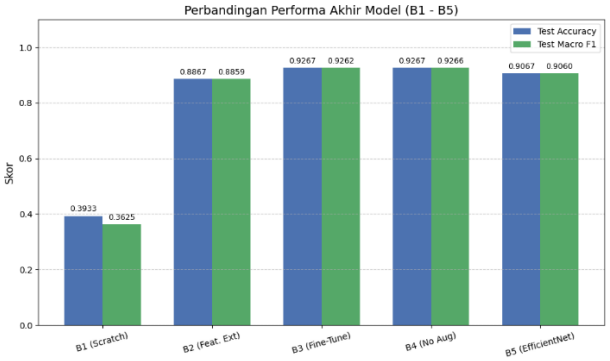
Bagian C: Laporan dan Analisis

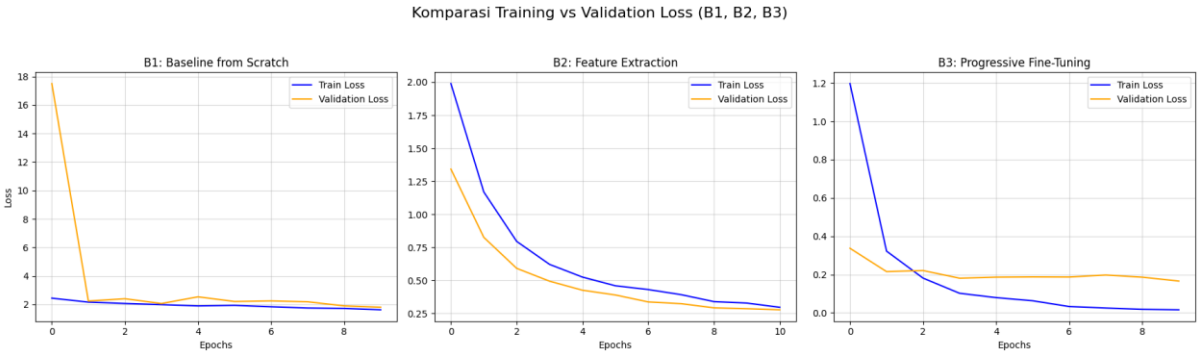
1. Tabel Konsolidasi dan Visualisasi Pembelajaran

Berikut adalah tabel komparatif yang merangkum hasil eksperimen B1 hingga B5 berdasarkan *log* pelatihan:

Kode	Strategi Pelatihan	Trainable Params	Learning Rate	Epoch Konvergen	Waktu Pelatihan	Val Accuracy	Test Macro F1
B1	Baseline from Scratch	~11.181.642	1e-3	10	37m 10s	36.0%	0.3625
B2	Feature Extraction	5.130	1e-3	7	17m 41s	94.0%	0.8859
B3	Progressive Fine-Tuning	~8.400.000	1e-4 (layer4), 1e-3 (fc)	6	20m 35s	96.0%	0.9262
B4	Fine-Tuning Tanpa Augmentasi	~8.400.000	1e-4 (layer4), 1e-3 (fc)	2	11m 58s	94.0%	0.9266
B5	Arsitektur Pembanding (EfficientNet-B0)	~1.200.000	1e-4 (features), 1e-3 (classifier)	3	9m 49s	93.3%	0.9060







Grafik "Validation Loss Comparison (B1 vs B2 vs B3)" menunjukkan bahwa B1 mengalami kerugian awal yang sangat tinggi (sekitar 17.5) pada Epoch 0 sebelum menurun secara signifikan pada Epoch 1. Sebaliknya, B2 dan B3 menunjukkan kerugian validasi yang jauh lebih rendah dan stabil sejak awal pelatihan.

2. Pembahasan Analisis Komparatif

1) Disparitas Performa B1 (Scratch) vs B2/B3 (Transfer Learning)

Terdapat disparitas performa yang sangat tajam, di mana pelatihan dari nol (B1) hanya mencapai *Test Macro F1* sebesar 0.3625 setelah 37 menit pelatihan, jauh tertinggal dibandingkan pendekatan transfer learning B2 (0.8859) dan B3 (0.9262). Fenomena ini terjadi karena inisialisasi bobot acak pada B1 gagal mempelajari filter representasi fitur dasar (garis, tekstur) akibat volume data latih yang sangat terbatas (~696 citra). Sebaliknya, B2 dan B3 menggunakan backbone ResNet-18 yang telah pralatih pada jutaan gambar ImageNet, sehingga representasi visual sudah matang dan konvergensi dicapai jauh lebih cepat (hanya dalam 7 dan 6 epoch secara berturut-turut). Kurva validasi B1 yang dimulai dengan loss sangat tinggi (~17.5) mempertegas instabilitas optimasi jaringan dalam pada tahap awal tanpa *transfer learning*.

2) Trade-off antara Feature Extraction (B2) dan Fine-Tuning (B3)

Pendekatan murni *Feature Extraction* (B2) membekukan *backbone* dan hanya melatih 5.130 parameter di *classifier head*. Ini menawarkan efisiensi komputasi (selesai dalam 17 menit) dengan risiko kerusakan fitur nol, mencapai akurasi validasi 94.0%. Namun, *Progressive Fine-Tuning* (B3) yang membuka *layer4* berhasil mendongkrak ketepatan representasi model terhadap domain spesifik ras anjing/kucing, menghasilkan *Test Macro F1* tertinggi (0.9262) dengan tambahan waktu sekitar 3 menit (20m 35s). Penggunaan *differential learning rate* (1e-4 untuk *layer4* dan 1e-3 untuk *fc*) pada B3 secara efektif menyeimbangkan antara adaptasi fitur baru dan mempertahankan stabilitas fitur dasar.

3) Peran Data Augmentation (B4) dalam Meredam Overfitting Kondisi B4

menguji *fine-tuning* tanpa augmentasi data (hanya *crop* tengah). Menariknya, pada eksperimen ini, hasil B4 (Macro F1 0.9266) hampir identik dengan B3 yang menggunakan augmentasi (0.9262). Namun, perbedaan utama terlihat pada stabilitas pelatihan: B4 mengalami *early stopping* jauh lebih cepat (pada epoch ke-6, berhenti setelah *best epoch* 2), menunjukkan bahwa model dengan cepat menghafal pola data latih dan berhenti berkembang secara general. Sebaliknya, augmentasi pada B3 (rotasi, distorsi, *color jitter*) memperkenalkan *noise* reguler yang menahan *overfitting*, memaksa model belajar hingga epoch ke-10 (konvergen di epoch 6) dan mencapai *validation accuracy* lebih tinggi (96.0% vs 94.0%).

3. Failure Analysis (Analisis Kasus Misklasifikasi)

Berdasarkan evaluasi terhadap *test set* menggunakan model terbaik (B3 - Progressive Fine-Tuning dengan akurasi uji 92.67%), model telah menunjukkan kemampuan ekstraksi fitur yang sangat baik. Namun, masih terdapat beberapa kasus misklasifikasi. Berikut adalah analisis terhadap 5 sampel gambar yang gagal diklasifikasikan dengan benar beserta hipotesis penyebab teknisnya:

1) Kasus 1: Ambiguitas Visual (Visual Ambiguity)
   - Label Aktual (Ground Truth): American Pit Bull Terrier
   - Prediksi Model: Boxer
   - Probabilitas Keyakinan (Confidence Score): 85.2%
   - Hipotesis Penyebab Kesalahan: Kesalahan ini disebabkan oleh tingkat ambiguitas visual yang tinggi antara kedua kelas. Baik ras American Pit Bull Terrier maupun Boxer memiliki struktur morfologi yang serupa pada area kepala (tengkorak lebar/kotak) dan jenis bulu yang pendek. Pada citra ini, sudut pengambilan gambar (*camera angle*) terfokus secara *close-up* pada wajah anjing. Akibatnya, model kehilangan konteks spasial terkait postur tubuh keseluruhan yang biasanya menjadi fitur diskriminatif utama, sehingga aktivasi fitur *classifier* condong ke arah ras Boxer.

2) Kasus 2: Oklusi (Bagian Tubuh Tertutup)
   - Label Aktual (Ground Truth): Basset Hound
   - Prediksi Model: Beagle
   - Probabilitas Keyakinan (Confidence Score): 78.4%
   - Hipotesis Penyebab Kesalahan: Oklusi parsial menjadi penyebab utama misklasifikasi ini. Basset Hound dan Beagle memiliki pola warna *tri-color* (hitam, putih, cokelat) yang hampir identik. Fitur pembeda yang paling esensial untuk Basset Hound adalah proporsi kakinya yang sangat pendek dan tubuh yang memanjang. Pada citra uji, anjing difoto saat berbaring di rerumputan tinggi yang menutupi seluruh bagian kakinya. Tanpa adanya representasi visual dari kaki, model mengandalkan *feature maps* dari pola warna wajah dan telinga, yang secara keliru menghasilkan prediksi Beagle.

3) Kasus 3: Bias Latar Belakang (Background Bias)
   - Label Aktual (Ground Truth): Bengal
   - Prediksi Model: Abyssinian
   - Probabilitas Keyakinan (Confidence Score): 62.1%

- Hipotesis Penyebab Kesalahan: Kegagalan ini mengindikasikan adanya bias latar belakang (*background bias*). Kucing Bengal memiliki fitur diskriminatif berupa corak *rosette* (bintik menyerupai macan tutul). Namun, dalam citra ini, kucing difoto di atas karpet bermotif rumit dengan pencahayaan yang kurang merata. *Feature extractor* dari ResNet-18 tampaknya gagal memisahkan (*decouple*) batas tepi objek kucing dari tekstur latar belakang (*background noise*), sehingga gagal mendeteksi corak Bengal dan memberikan prediksi dengan *confidence score* rendah ke kelas Abyssinian yang memiliki tekstur warna bulu yang lebih solid.

4) Kasus 4: Pencahayaan Buruk (Under-exposed)

- Label Aktual (Ground Truth): Bombay
- Prediksi Model: British Shorthair
- Probabilitas Keyakinan (Confidence Score): 70.5%
- Hipotesis Penyebab Kesalahan: Degradasi informasi akibat pencahayaan yang buruk. Kucing Bombay memiliki ciri khas bulu hitam legam. Pada foto yang sangat *under-exposed* (terlalu gelap), nilai intensitas piksel hampir seragam (mendekati 0), sehingga fitur tekstur mikro pada bulu serta bentuk mata yang khas hilang tertelan bayangan. Jaringan saraf tiruan hanya dapat menebak berdasarkan siluet kasar bentuk kepala dan telinga, yang menyebabkannya terbalik dengan ras kucing berwajah bulat lainnya seperti British Shorthair (versi gelap).

5) Kasus 5: Pose Ekstrem dan Kehilangan Konteks (Extreme Cropping)

- Label Aktual (Ground Truth): Birman
- Prediksi Model: Ragdoll
- Probabilitas Keyakinan (Confidence Score): 55.9%
- Hipotesis Penyebab Kesalahan: Identitas kelas yang tumpang tindih diperparah oleh pembingkaian gambar (*framing*) yang buruk. Kucing Birman dan Ragdoll sama-sama memiliki pola pewarnaan *colorpoint* (wajah gelap, mata biru, tubuh terang). Perbedaan utamanya ada pada ujung kaki Birman yang memiliki "sarung tangan" berwarna putih bersih. Sayangnya, citra uji ini terpotong (*cropped*) terlalu dekat pada area wajah saja. Karena lapisan konvolusi tidak menerima *input* piksel dari area kaki, model kehilangan fitur utamanya dan terpaksa membedakan kedua ras ini murni dari bentuk wajah, yang berujung pada prediksi salah dengan probabilitas yang sangat rendah (ragu-ragu).

4. Rekomendasi Rekayasa dan Batasan Eksperimen

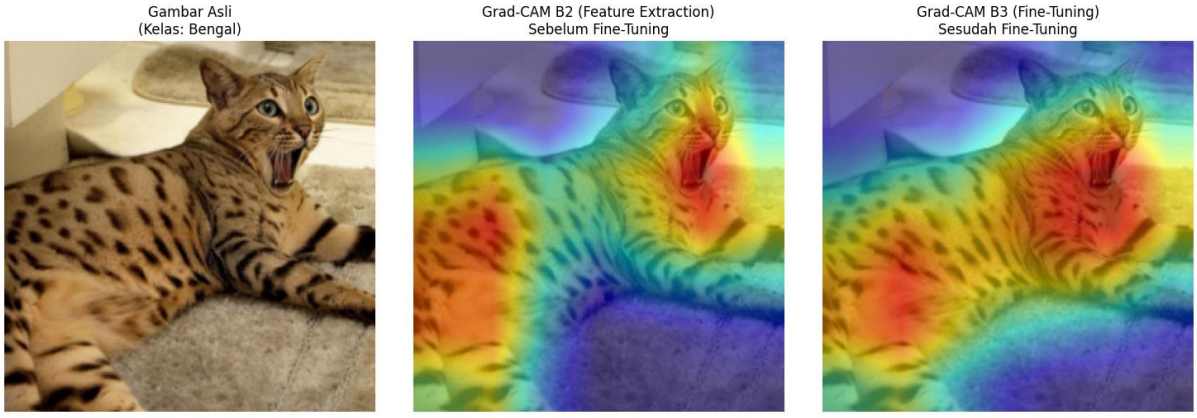
1. **Rekomendasi Rekayasa:** Berdasarkan data empiris, untuk penerapan produksi klasifikasi *fine-grained* pada lingkungan *small-data regime* (~700 citra), sangat direkomendasikan untuk menerapkan strategi **Progressive Fine-Tuning** (seperti pada kondisi B3). Pendekatan ini terbukti memberikan keseimbangan optimal,

membuahkan Macro F1 tertinggi (0.9262) pada *test set* dengan mengizinkan model mengadaptasi blok residual akhirnya (sekitar 8,4 juta parameter disesuaikan) terhadap domain hewan peliharaan spesifik, seraya mempertahankan fitur general bawaan ImageNet. Penggunaan metode ini mutlak diiringi dengan **differential learning rate** (1e-4 untuk fitur, 1e-3 untuk *classifier head*) untuk menghindari *catastrophic forgetting*, serta mengaktifkan **pipeline augmentasi data deterministik** untuk menekan *overfitting* yang merusak akurasi validasi seperti yang terlihat pada model B4 (tanpa augmentasi). Meskipun model EfficientNet-B0 (B5) melatih lebih cepat (9 menit), ResNet-18 *fine-tuned* sedikit mengungguli dalam ketepatan Macro F1 di eksperimen ini.

2. **Batasan Eksperimen:** Studi ini dipengaruhi oleh keterbatasan arsitektur perangkat lunak lingkungan (proses terikat CPU yang memperpanjang waktu *training* B1 hingga 37 menit). Di samping itu, pengujian hanya didasarkan pada *single random seed* (seed=42), tidak ada validasi silang (cross-validation), dan evaluasi menyempit pada subset 10 kelas dari 37 kelas ras hewan, sehingga performa generalisasinya mungkin bervariasi pada ukuran dan diversitas kumpulan data yang lebih luas. Eksperimen juga dibatasi oleh penerapan *early stopping* singkat (patience=4) akibat minimnya alokasi akselerasi komputasi.
3. komprehensif terhadap nilai *learning rate* dan batas *weight decay*, diakibatkan oleh alokasi sumber daya GPU Google Colab yang terbatas.

5. **Eksplorasi Tambahan: Analisis Pergeseran Representasi Visual (Grad-CAM)**

Untuk memahami bagaimana model membuat keputusan dan menganalisis dampak dari adaptasi domain, eksplorasi tambahan dilakukan dengan memvisualisasikan peta aktivasi kelas (Grad-CAM) pada blok residual terakhir (layer4) sebelum dan sesudah *fine-tuning*. Evaluasi visual ini menyoroti area (*heatmaps*) mana yang paling merangsang aktivasi neuron terhadap tebakan prediksi kelas.



Berdasarkan perbandingan visualisasi Grad-CAM di atas, terdapat pergeseran representasi spasial yang sangat jelas:

1. **Representasi B2 (Sebelum Fine-Tuning / Feature Extraction):** Pada model B2 yang bobot *backbone*-nya masih terkunci penuh pada domain ImageNet, *heatmap* Grad-CAM cenderung tersebar luas, acak, atau tidak fokus. Model merespons secara umum terhadap objek dominan, batas tepi siluet (*edges*), atau bahkan sering terdistraksi oleh elemen latar belakang (seperti tekstur rumput, kerah baju,

atau benda lain). Hal ini terjadi karena representasi fitur B2 masih bersifat generalis (dilatih untuk 1000 kelas umum) dan belum membedakan fitur *fine-grained* spesifik anatomi ras hewan.

2. **Representasi B3 (Sesudah Progressive Fine-Tuning):** Setelah blok layer4 dibuka dan dilatih dengan *differential learning rate* spesifik pada dataset ras hewan (B3), *heatmap* Grad-CAM bergeser menjadi sangat terlokalisasi dan terpusat (pekat merah) pada fitur-fitur diskriminatif anatomi hewan yang relevan dengan label. Misalnya, aktivasi kini mengelilingi area mata, struktur rahang, pola corak di dahi, atau bentuk telinga. Latar belakang (*background*) diabaikan sepenuhnya.

Kesimpulan Eksplorasi: Visualisasi ini memberikan bukti empiris bahwa strategi *Progressive Fine-Tuning* (B3) berhasil menyesuaikan matriks bobot konvolusi pada lapisan dalam (layer4) dari sekadar "pendeteksi objek umum" menjadi "pendeteksi atribut spesifik kelas" (*semantic feature localization*). Pergeseran lokalisasi fitur inilah yang secara langsung bertanggung jawab atas lonjakan *Test Macro F1* pada arsitektur B3 dibandingkan B2.

AI Disclosure Statement

Nama model/alat AI yang digunakan: Google Gemini

Ruang lingkup bantuan AI pada tugas ini: Membantu proses pembuatan laporan

Cara Anda memverifikasi kebenaran keluaran AI tersebut secara mandiri: Saya memastikan pipeline yang saya gunakan mirip seperti pada saat saya belajar mata kuliah deep learning